

AI 使用说明情况

AI 模型: Deepseek V4.1 Flash

提示词:

1.一, 背景 一个完整的大模型应用不仅包括模型本身, 还包括模型部署、请求调度、推理优化、缓存管理以及服务架构设计等多个环节。当用户向大模型发送请求时, 请求并不会简单地直接输入模型, 而是需要经过推理服务框架进行处理, 包括请求接收、任务调度、输入计算 (Prefill)、输出生成 (Decode) 以及缓存管理等过程。 client→tokenizer→scheduler / queue→prefill→KV Cache / RadixCache→decode iterations→sampling→streaming output→metric 本挑战希望同学们通过部署并使用 SGLang 在线推理框架, 亲身体验一次完整的大模型服务流程, 并进一步理解现代推理系统中的关键优化技术, 包括 RadixAttention、RadixCache、KV Cache、Prefix Reuse 等。同时, 通过模拟真实业务请求 workload, 使同学能够从单次模型调用扩展到在线服务系统层面, 理解大模型推理性能优化背后的系统设计思想。 二, 创建 github 账号并创建公开仓库 三, 部署以及环境要求 在本地环境中启动 SGLangOpenAI-compatible 服务, 能访问 /v1/models, 并完成一次推理请求。 第一步: 准备环境 建议 Ubuntu / WSL。 环境要求: SGLang 0.5.14 Ray 2.56.0 模型 Qwen/Qwen3-0.6B 并且 SGLang 和 Ray 可以放在不同 Python 环境, 通过 HTTP 通信。 使用要求的模型: Qwen/Qwen3-0.6B 四, 挑战内容 在本地环境中启动 SGLangOpenAI-compatible 服务, 能访问 /v1/models, 并完成一次推理请求。 1. 发送一次推理请求并截图保存 (截图 1) 2. Mooncake trace 采样 workload 从 Mooncake FAST' 25 trace 中采样 10-30 条请求记录, 例如 arxiv-trace/mooncake_trace.jsonl。根据 input_length 和 output_length 构造 synthetic prompt, 用 Poisson 到达过程生成请求时间, 并将这组小 workload 发送到 SGLang。记录每个请求的 input tokens、output tokens、status、TTFT 或 latency。截图保存 (截图 2) 3. 用一张流程图讲清一次请求如何经过 SGLang 在线推理框架, 重点放在流程上 4. 重点回答: • SGLang 的 RadixAttention / RadixCache 解决什么问题? • SGLang 中 page-sized KV cache 与 prefix reuse 分别对应 pipeline 中的哪一部分? • vLLM 的 PagedAttention 解决什么问题? 它和 SGLang 的 RadixAttention / paged KV 机制有什么联系与差异? 答案文件不超过一页

我现在对 AI 方面毫无所知, 请你指导我完成环境和 AI 部署。但是首先, 你先别着急做, 你先检查一下我的整个电脑中, 有没有已经装了的部分。如果没有, 你先告诉我情况, 当我下达开始指令后我们再开始安装

2. 可是我想自己操作一遍, 然后自己截图、写报告, 自己体会一遍。所以你现在的任务是一步步教我按要求启动。你直接口述吧

```
3. (base) sjy@SJY111-Laptop:~$ curl -s
http://127.0.0.1:30000/v1/chat/completions \ -H "Content-Type:
application/json" \ -d '{ "model": "Qwen3-0.6B", "messages": [{"role":
"user", "content": "用一句话解释什么是 KV Cache"}], "max_tokens": 128,
"temperature": 0, "chat_template_kwargs": {"enable_thinking": false} }'
| python3 -m json.tool { "id": "a8f7f4ca8d03480c9ad5b2586bb670a2",
"object": "chat.completion", "created": 1790435453, "model":
"Qwen3-0.6B", "choices": [ { "index": 0, "message": { "role": "assistant",
```

"content": "KV Cache
\u662f\u4e00\u79cd\u7528\u4e8e\u7f13\u5b58\u952e\u503c\u5bf9\u5bf9Key-Value\u5bf9\u6570\u636e\u7684\u5185\u5b58\u7ed3\u6784\u5bf9\u7528\u4e8e\u51cf\u5111\u91cd\u590d\u8bbf\u95ee\u548c\u63d0\u9ad8\u6570\u636e\u8bbf\u95ee\u6548\u7387\u3002", "reasoning_content": null, "tool_calls": null }, "logprobs": null, "finish_reason": "stop", "matched_stop": 151645 }], "usage": { "prompt_tokens": 18, "total_tokens": 49, "completion_tokens": 31, "prompt_tokens_details": null, "reasoning_tokens": 0 }, "metadata": { "weight_version": "default" } } 这是终端的反馈，为什么第一个窗口里的千问一点动静都没有

4. (base) sjy@SJY111-Laptop:~\$ curl -s http://127.0.0.1:30000/v1/chat/completions \ -H "Content-Type: application/json" \ -d '{ "model": "Qwen3-0.6B", "messages": [{"role": "user", "content": "用一句话解释什么是 KV Cache"}], "max_tokens": 128, "temperature": 0, "chat_template_kwargs": {"enable_thinking": false} }' | python3 -m json.tool { "id": "a8f7f4ca8d03480c9ad5b2586bb670a2", "object": "chat.completion", "created": 1790435453, "model": "Qwen3-0.6B", "choices": [{ "index": 0, "message": { "role": "assistant", "content": "KV Cache
\u662f\u4e00\u79cd\u7528\u4e8e\u7f13\u5b58\u952e\u503c\u5bf9\u5bf9Key-Value\u5bf9\u6570\u636e\u7684\u5185\u5b58\u7ed3\u6784\u5bf9\u7528\u4e8e\u51cf\u5111\u91cd\u590d\u8bbf\u95ee\u548c\u63d0\u9ad8\u6570\u636e\u8bbf\u95ee\u6548\u7387\u3002", "reasoning_content": null, "tool_calls": null }, "logprobs": null, "finish_reason": "stop", "matched_stop": 151645 }], "usage": { "prompt_tokens": 18, "total_tokens": 49, "completion_tokens": 31, "prompt_tokens_details": null, "reasoning_tokens": 0 }, "metadata": { "weight_version": "default" } } 你解释一下它的反馈 每句话都是什么意思

5. "content": "KV Cache
\u662f\u4e00\u79cd\u7528\u4e8e\u7f13\u5b58\u952e\u503c\u5bf9\u5bf9Key-Value\u5bf9\u6570\u636e\u7684\u5185\u5b58\u7ed3\u6784\u5bf9\u7528\u4e8e\u51cf\u5111\u91cd\u590d\u8bbf\u95ee\u548c\u63d0\u9ad8\u6570\u636e\u8bbf\u95ee\u6548\u7387\u3002", 所以这句话是千问的回答吗？

6. 现在我要完成挑战里的 1. 发送一次推理请求并截图保存，我要截哪个窗口的哪些内容？

7. 用一张流程图讲清一次请求如何经过 SGLang 在线推理框架，重点放在流程上这个我不会，你帮我画一下吧

8. 你用最通俗易懂的语言讲解一下整个过程是怎么工作的