

```
(base) sjy@SJY111-Laptop: /mnt/d/SGLang504$ python3 scripts/03_mooncake_workload.py --trace data/mooncake_trace.jsonl --num 20 --rate 0.5 --seed 2026
=====
Mooncake trace 采样 + Poisson 到达压测
=====
trace 总条数      : 23608
可用采样池      : 7223 条 (限制 512 <= input_length <= 6144, 16 <= output_length <= 512)
实际采样        : 20 条
任务到达过程    : Poisson, lambda = 0.5 req/s (平均间隔 2.00 s)

-----
#   到达(s)   in_len out_len   可复用前缀   hash_ids 数
-----
1   0.25     1877    480         0           4
2   1.65     3152     16         0           7
3   3.08     5161    167        512          11
4   7.02     1522     96        512           3
5   7.23      906    462        512           2
6   7.74     3112     18       2560           7
7   9.58     3140     20       2560           7
8  11.20     1159    201        512           3
9  14.26     3007     18       2560           6
10 15.85     1469    154        512           3
11 18.47     3165     16       2560           7
12 21.39     3965    442        512           8
13 24.18     3141     18       2560           7
14 25.94     1874     65        512           4
15 26.49     3918    397        512           8
16 28.39     1604    214        512           4
17 28.63     1306     17        512           3
18 32.02     3150     16       2560           7
19 33.22     1174     18        512           3
20 36.59     3150     22       2560           7
-----
有可复用前缀的请求: 18/20; 总可复用 token 数 = 23552

服务探活成功, 已加载模型: ['Qwen3-0.6B']

-----
#   发车(s)   TTFT(ms)   延迟(ms)   in_tok out_tok   可复用   状态
-----
1   0.25     217.15    2546.60    1877   480         0      ok
2   1.65     121.18    208.10     3152    16         0      ok
3   3.08     202.13    1128.61    5161   167        512     ok
4   7.02     167.29    675.83    1522    96        512     ok
5   7.23      27.24    2113.35     906   462        512     ok
6   7.74      35.88    128.78    3112    18       2560     ok
7   9.58      40.24    132.49    3140    20       2560     ok
8  11.20      33.45    904.95    1159   201        512     ok
-----
```

```
-----
#   发车(s)   TTFT(ms)   延迟(ms)   in_tok out_tok   可复用   状态
-----
1   0.25     217.15    2546.60    1877   480         0      ok
2   1.65     121.18    208.10     3152    16         0      ok
3   3.08     202.13    1128.61    5161   167        512     ok
4   7.02     167.29    675.83    1522    96        512     ok
5   7.23      27.24    2113.35     906   462        512     ok
6   7.74      35.88    128.78    3112    18       2560     ok
7   9.58      40.24    132.49    3140    20       2560     ok
8  11.20      33.45    904.95    1159   201        512     ok
9  14.26      31.61    114.51    3007    18       2560     ok
10 15.85      38.72    775.91    1469    154        512     ok
11 18.47      38.58    112.44    3165    16       2560     ok
12 21.39     142.15    2574.83    3965    442        512     ok
13 24.18      37.88    121.66    3141    18       2560     ok
14 25.94      55.68    346.69    1874    65        512     ok
15 26.49     136.04    2335.45    3918    397        512     ok
16 28.39      52.50    1132.67    1604    214        512     ok
17 28.63      40.69    142.16    1306    17        512     ok
18 32.02     130.86    203.63    3150    16       2560     ok
19 33.22      31.66    123.89    1174    18        512     ok
20 36.59      38.84    169.94    3150    22       2560     ok
-----

成功请求      : 20/20
TTFT (ms)     : mean=81.0  p50=40.5  min=27.2  max=217.2
端到端延迟 (ms) : mean=799.6  p50=277.4  min=112.4  max=2574.8
总墙钟时间 (s)  : 36.76
实际吞吐 (req/s) : 0.544

前缀复用效果对比 (RadixCache 命中 vs 未命中) :
命中前缀的请求 n=18 平均 TTFT = 71.2 ms
无前缀复用的请求 n=2 平均 TTFT = 169.2 ms
=====
明细已保存: /mnt/d/SGLang504/data/workload_result.csv
           /mnt/d/SGLang504/data/workload_result.json
```

```
(base) sjy@SJY111-Laptop:~$ curl -s http://127.0.0.1:38000/v1/models | python3 -m json.tool
{
  "object": "list",
  "data": [
    {
      "id": "Qwen3-0.6B",
      "object": "model",
      "created": 1790480019,
      "owned_by": "sglang",
      "root": "Qwen3-0.6B",
      "parent": null,
      "max_model_len": 8192
    }
  ]
}
(base) sjy@SJY111-Laptop:~$ curl -s http://127.0.0.1:38000/v1/chat/completions -H "Content-Type: application/json" \
-d '{"model": "Qwen3-0.6B", "messages": [{"role": "user", "content": "问一下十二生肖"}], "max_tokens": 64, "chat_template_kwargs": {"enable_thinking": false}}' \
| python3 -m json.tool --no-ensure-ascii
{
  "id": "1399b63decc04adda2d7cc263ba9bb4e",
  "object": "chat.completion",
  "created": 1790480074,
  "model": "Qwen3-0.6B",
  "choices": [
    {
      "index": 0,
      "message": {
        "role": "assistant",
        "content": "十二生肖是中国传统文化中重要的组成部分，通常用于指导人们的生活、工作和学习。每个生肖都有其独特的象征意义和对应的季节，比如鼠、牛、虎、兔等代表不同的性格特征和命运走向。\\n\\n如果你有具体的兴趣或需要了解某个生肖的详细信息，欢迎告诉我，我可以为你",
        "reasoning_content": null,
        "tool_calls": null
      },
      "logprobs": null,
      "finish_reason": "length",
      "matched_stop": null
    }
  ],
  "usage": {
    "prompt_tokens": 16,
    "total_tokens": 80,
    "completion_tokens": 64,
    "prompt_tokens_details": null,
    "reasoning_tokens": 0
  },
  "metadata": {
    "weight_version": "default"
  }
}
(base) sjy@SJY111-Laptop:~$ |
```