

阅读文献笔记

1. PagedAttention 的提出者受到操作系统应对内存碎片的管理方案启发，将请求的 KV 缓存划分为若干块，每块可容纳固定数量 token 的注意力键与值，KV 缓存的块不必存储在连续空间中。因此，PagedAttention 可以像 OS 的虚拟内存那样更灵活地管理 KV 缓存：可以把块看作页（page），把 token 看作字节，把请求看作进程。
2. GPU 算力的增长速度超过显存容量的增长。例如，从 NVIDIA A100 到 H100，FLOPS 增长超过 2 倍，而 GPU 显存最多仍停留在 80GB。因此显存将成为愈发严重的瓶颈。
3. 大模型的应用从简单聊天变成系统性调用工具及解决复杂任务，此时 RadixAttention、压缩有限状态机来加速 SGLang 程序的执行